

Trabajo Práctico II

Filtros de Imagen

Organización del Computador II Primer Cuatrimestre - 2015

Integrante	LU	Correo electrónico
Christian Cuneo	755/13	chriscuneo93@gmail.com
Ignacio Lebrero	751/13	ignaciolebrero@gmail.com
Jorge Porto	376/11	cuanto.p.p@gmail.com



Facultad de Ciencias Exactas y Naturales Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja) Intendente Güiraldes 2160 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (54 11) 4576-3359 http://www.fcen.uba.ar

Índice

1.	Introducción	1
2.	Desarrollo	2
	2.1. Blur	2
	2.1.1. Implementación en assembler 1	2
	2.1.2. Implementación en assembler 2	3
	2.2. Merge	4
	2.2.1. Implementación en assembler 1	4
	2.2.2. Implementación en assembler 2	6
	2.3. HSL	7
	2.3.1. Implementación en assembler 1	8
	2.3.2. Implementación en assembler 2	9
3.	Experimentación	12
	3.1. Blur	12
	3.1.1. Metodo de iteración	13
	3.2. Merge	14
	3.3. HSL	16
	3.3.1. Implementación	16
	3.3.2. Variación 1	17
	3.3.3. Variación 2	18
	3.3.4. Experimentos Futuros	18
4.	Conclusiones v trabajo futuro	19

1. Introducción

Los filtros de imagen son una herramienta poderosa a la hora de retocar una imagen, usados ampliamente en fotografía, publicidad, video-juegos, etc. Su uso brinda una gamma de opciones para modificar las imágenes de manera que sea mas flexible su edición o análisis.

En este trabajo practico presentamos los métodos blur, merge y hsl ya existentes y los implementamos en lenguaje de ensamblador. Damos dos implementaciones de cada filtro siendo la segunda una optimización de la primera en merge y blur, y una variación de implementación C/Assembler a Assembler en hsl. Finalmente realizamos experimentos para comparar el tiempo de computo de los mismos.

El lenguaje C es uno de los más eficientes en cuestión de performance, pero es posible mejorarla implementando las funciones directamente en assembler. En este trabajo se pondrá énfasis en las posible ventajas que puede tener un código en assembler con respecto a uno en C, y también las ventajas de usar las e instrucciones SIMD de la arquitectura x86-64.

2. Desarrollo

2.1. Blur

El filtro blur genera una imagen desenfocada artificialmente, que usa un método muy simple para lograrlo, a cada pixel se lo promedia con todos sus pixeles vecinos y se guarda ese resultado en el mismo pixel.

2.1.1. Implementación en assembler 1

El principio básico de la implementación en assembler es que la iteración de la imagen imagen se realiza de arriba a abajo y de izquierda a derecha (viendo la imagen siempre como una matriz). Con este método se obtiene una ventaja muy interesante, uno reutiliza las filas ya cargadas a la hora de procesar el siguiente pixel, y solo tiene que cargar una fila mas por cada pixel a procesar, esto es una ventaja ya que uno busca una menor lectura de memoria, ya que es una tarea muy costosa. En el pseudocódigo siguiente se vera mas detalladamente el funcionamiento de este método:

```
1 for (x = 1 to n - 2):
      xmm1 \leftarrow img[x-1][0], img[x][0], img[x+1][0], img[x+2][0]
 3
      xmm2 \leftarrow img[x-1][1], img[x][1], img[x+1][1], img[x+2][1]
 4
      xmm1 <-- borrarprimero(xmm1)</pre>
 5
      xmm2 <-- borrarprimero(xmm2)</pre>
 6
      xmm1 <-- sumapixels(xmm1)</pre>
 7
      xmm2 <-- sumapixels(xmm2)</pre>
 8
      for (y = 1 \text{ to } n - 2):
 9
         xmm0 <-- xmm1
10
         xmm1 <-- xmm2
11
         xmm3 \leftarrow img[x-1][y+1], img[x][y+1], img[x+1][y+1], img[x+2][y+1]
12.
         xmm3 <-- borrarprimero(xmm3)</pre>
         xmm3 <-- sumapixels(xmm3)</pre>
13
14
         xmm0 < -- xmm0 + xmm1 + xmm2
15
         xmm0 <-- promedio(xmm0)</pre>
16
         img[x][y] <-- xmm0</pre>
17
      end
18 end
```

Cada pixel contiene 4 valores de 1 byte (R, G, B y A), por lo tanto entran 4 pixels en un registro xmm, entonces cargo directamente 4 pixels de memoria. Hay que tener en cuenta que se cargan los pixels del [x-1] al [x+2], pero en el registro van a quedar al revez, siendo primero el [x+2].

La función "borrarprimero" va a utilizar la instrucción PINSRD para insertar 0 en los primeros 4 bytes, eliminando así los datos de el primer pixel en el registro, que seria el pixel x+2, ya que es el pixel que no nos interesa, porque solo hay que promediar con los vecinos del pixel img[x][y], es decir los pixeles img[i][j] con $i\in(x-1, x, x+1)$ y $j\in(y-1, y, y+1)$.

La función "sumarpixels" va a sumar los pixeles dentro del registro por valor (R, G, B y A). Para lograr esto sin saturación se necesita extender (con ceros) los valores de 1 byte a 2 bytes, para poder representar, sin ningún problema, la suma de todos los valores posibles. Para esto se utiliza la instrucción PUNPCKLBW y PUNPCKHBW (ambas con un registro nulo como source), para guardar en un registro los 2 pixels menos significativos y los 2 pixels mas significativos respectivamente. Se necesita guardar en dos registros ya que al ocupar cada dato el doble, van a entrar la mitad de datos en el registro. Luego de extender los valores se procede a sumar horizontalmente cada registro y luego se suman de forma empaquetada a word los dos registros, y nos queda en el qword menos significativo el pixel suma de los pixels que había originalmente en el registro.

La función "promedio", dado un registro con la suma (de todos los pixeles a promediar) en el qword menos significativo, va a devolver un pixel con cada valor original dividido por 9, y va a devolver este pixel de forma que quede listo para ser grabado a memoria (quiere decir los R, G, B y A de 1 byte cada uno y ordenados). Para ello primero extiende (con ceros) de word a dword cada valor del pixel, utilizando la instrucción PUNPCKLWD con un registro nulo como source. Luego se convierte cada valor de entero de 32 bits a single-precision floating point, que es también de 32 bits, con la instrucción CVTDQ2PS. Entonces se procede a dividirlos por 9 en forma empaquetada utilizando la instrucción DIVPS, usando como source un registro previamente cargado con cuatro "9" en float. Luego se van a convertir de nuevo a enteros utilizando la instrucción CVTPS2DQ. En este punto ya sabemos que no importe que valores hayan tenido los 9 pixeles sumados, al promediarlos van a dar números entre 255 y 0 unicamente, entonces al convertirlos de nuevo a enteros sabemos que van a quedar valores que van a ocupar como mucho los 8 bits menos significativos de cada dword. Teniendo en cuenta esa información se puede proceder a hacer un shuffle (con la instrucción PSHUFB) para mover cada byte menos significativo de cada dword a la posición correcta del registro, quedando en el dword menos significativo del registro el pixel a guardar, con sus valores en el orden correcto. En esta instrucción se utiliza una mascara especifica que se puede ver en la implementación.

Finalmente se graba a memoria el resultado utilizando la instrucción PEXTRD [mmx], xmm, 00b, siendo mmx el puntero al destino donde guardar los datos y xmm el resultado del promedio, se utiliza "00" ya que el resultado de calcular el promedio se encuentra en el dword menos significativo.

Una cuestión a tener en cuenta de esta implementación es que, al ser el array "img" la imagen a procesar y el destino donde guardar el resultado, se tuvo que asignar un espacio de igual tamaño al de "img" para guardar el resultado en ese espacio, ya que si se guarda en el mismo "img" se estarían promediando los pixels con pixels que son un promedio de por si. Entonces se guarda el resultado en este espacio pedido usando malloc, y luego de procesar toda la imagen, se copia todo el contenido de este resultado a la imagen original usando un loop construido con jumps condicionales, y luego se hace un free de esta memoria.

También algo muy importante es que, como se ve en el pseudocodigo, uno siempre carga de a 4 pixeles, descartando el cuarto pixel en el proceso posterior. Esto va a comportarse de forma no deseada al llegar al x = n - 2, ya que al cargar el registro estarías accediendo datos que no pertenecen a la fila deseada, esto no es un problema al principio, ya que se estaría cargando el primer pixel de la siguiente fila, lo cual esta permitido. Pero al llegar también al y = n - 2 uno estaría tratando de acceder algo que no nos pertenece, ya que estaríamos en la ultima fila de la imagen. Para esto la implementación se encarga de detectar cuando se llega a este caso en particular (etiqueta "lastpixel") y simplemente se cargan los últimos 4 pixeles, y se realiza un PSRLDQ para luego seguir normalmente con el algoritmo.

2.1.2. Implementación en assembler 2

La implementación numero 2 hace el mismo procedimiento que la implementación 1, solo que procesa de a 4 pixeles por iteración, para esto se van a necesitar cargar 6 pixeles de la fila de pixeles a procesar, de la siguiente y la anterior, como se ve en la siguiente imagen:

0	1	2	2	4	Е
U	Τ	2	3	4	Э
6	7		9	10	11
12	13	14	15	16	17

5	4	3	2
11	10	9	8
17	16	15	14

L	3	2	1	0
	9	8	7	6
	15	14	13	12

Figura 1: Los pixeles que se deberán cargar al procesar los pixeles marcados con rojo. Se cargaran en 6 xmm como se muestra a la derecha

Luego estos registros se va a extender con ceros los valores de todos los pixeles (con las instrucciones PUNPCKLBW y PUNPCKHBW con source un registro xmm nulo), para ello se usa PUNPCKLBW en los 3 registros de la izquierda; luego PUNPCKLBW y PUNPCKHBW en los de la izquierda, seria lo mismo al revés, ya que hay dos pixeles que se repiten para cada fila:

xmm2 Bs Gs Rs As B4 G4 R4 A4	xmm1 B ₃ G ₃ R ₃ A ₃ B ₂ G ₂ R ₂ A ₂	xmm0 B_1 G_1 R_1 A_1 B_0 G_0 R_0 A_0
$xmm5$ B_{11} G_{11} R_{11} A_{11} B_{10} G_{10} R_{10} A_{10}	xmm4 B9 G9 R9 A9 B8 G8 R8 A8	xmm3 B7 G7 R7 A7 B6 G6 R6 A6
xmm8 B_{17} G_{17} R_{17} A_{17} B_{16} G_{16} R_{16} A_{16}	$xmm7$ B_{15} G_{15} R_{15} A_{15} B_{14} G_{14} R_{14} A_{14}	$xmm6$ B_{13} G_{13} R_{13} A_{13} B_{12} G_{12} R_{12} A_{12}

Figura 2: Registros luego de desempaquetar

Se extendieron los valores para poder sumarlos sin que se lleguen a saturar, luego se suman respetando las columnas usando PADDW de la siguiente manera:

xmm2 Bs + B11+ B17 Gs+ G11+G	7 Rs + R11+ R17 As + A11+ A17	B4 + B10+ B16 G4+ G10+ G16	R ₄ + R ₁₀ + R ₁₆ A ₄ + A ₁₀ + A ₁₆
xmm1 B ₃ + B ₉ + B ₁₅ G ₃ + G ₉ + C	1 R ₃ + R ₉ + R ₁₅ A ₃ + A ₉ + A ₁₅	B ₂ + B ₈ + B ₁₄ G ₂ + G ₈ + G ₁₄	R ₂ + R ₈ + R ₁₄ A ₂ + A ₈ + A ₁₄
xmm0 B ₁ + B ₇ + B ₁₃ G ₁ + G ₇ + G	3 R ₁ + R ₇ + R ₁₃ A ₁ + A ₇ + A ₁₃	B ₀ + B ₆ +B ₁₂ G ₀ + G ₆ +G ₁₂	$R_0 + R_6 + R_{12} A_0 + A_6 + A_{12}$

Figura 3: Registros luego de sumar, sumamos en xmm0, xmm1 y xmm2 ya que no se van a necesitar para el ciclo siguiente.

A partir de esas sumas se pueden obtener los valores resultantes para los 4 pixeles de la iteración de la siguiente forma:

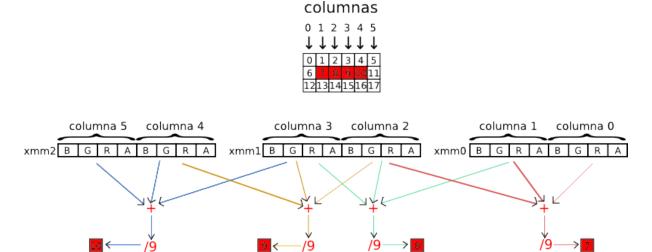


Figura 4: Pasos a seguir para cada pixel.

En el proceso para cada pixel, primero se extenderán los valores a dword con el mismo procedimiento explicado anteriormente (esto se hace para poder, mas adelante, pasarlo a single precision floating point in place). Luego, la operación suma entre los registros se realiza con la instrucción PADDD, luego se convierten los valores a FP con CVTDQ2PS, se dividen por 9 usando DIVPS, y se convierte de nuevo a enteros CVTPS2DQ. Por ultimo se hace el mismo shuffle que en la implementación 1, para terminar grabando el resultado al bloque de memoria temporal.

2.2. Merge

El merge nos permite a partir de dos imágenes y un valor entre cero y uno, obtener una combinación de estas ultimas según la proporción indicada por el valor.

2.2.1. Implementación en assembler 1

Se recibe por parámetro dos punteros a dos imágenes almacenadas en memoria como una matriz de pixeles. Como los pixeles de estas imágenes ocupan 4 byte, y la cantidad de pixeles de las mismas es múltiplo de 4, utilizando los registros xmm podemos traer de a 4 pixeles. Luego incrementamos los punteros a la imagen en 16 bytes y volvemos a traer los pixeles de memoria. De esta manera tenemos

un ciclo principal cuya cantidad de iteraciones es la cantidad de pixeles dividido cuatro. Cada una de estas consiste en levantar de memoria cuatro pixeles y almacenarlos en un registro xmm, cuyo contenido puede verse en la figura 5.

B | G | R | A | B | G | R | A | B | G | R | A | B | G | R | A

Figura 5: Contenido del registro xmm al levantar de memoria cuatro pixeles

Luego utilizando la instrucción pshufb y una masara apropiada ordenamos su contenido para que quede como se muestra en la figura 6

Figura 6: Contenido del registro xmm luego de utilizar la instrucción pshufb

Utilizamos las instrucciones de desempaquetado de SIMD y un registro xmm lleno de ceros, para desempaquetar la parte alta y baja, obtenemos registros xmm con el contenido como se muestra en la figura 7.

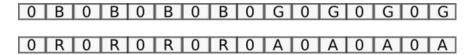


Figura 7: Contenido resultante de desempaquetar parte alta y baja

Luego volvemos a desempaquetar parte alta y baja de los dos registros obtenidos, y obtenemos cuatro registros xmm como se indica en la figura 8.

0 0 0	В	0	0	0	В	0	0	0	В	0	0	0	В
0 0 0	G	0	0	0	G	0	0	0	G	0	0	0	G
0 0 0													
0 0 0													

Figura 8: Contenido resultante de desempaquetar parte alta y baja nuevamente

Utilizando la instrucción cvtdq2ps convertimos los cuatro valores de los registros de la figura 8, excepto el que contiene los bytes de transparencia(A), a tipo flotante. El objetivo es multiplicar cada color por value. Para hacer esto, previo al ciclo, utilizando la instrucción shufps, conseguimos en un registro xmm cuatro valores de tipo flotante con el valor que indica el índice de combinación de imágenes pasado por parámetro, y en otro cuatro valores con 1-value tal como se indica en la figura 9.

value	value	value	value
1 - value	1 - value	1 - value	1 - value

Figura 9: Contenido de los registros utilizados para multiplicar por value los colores

Utilizando la instrucción de SIMD mulps, multiplicamos los colores transformados a tipo flotante por value.

Se repite el procedimiento para la segunda imagen, excepto que no se desempaqueta el byte de transparencia(A), ya que solo interesa los bytes de transparencia de la primera imagen. En este caso multiplicamos por 1-value. Sumamos con la instrucción addps los valores obtenidos en la multiplicación, para los colores azul, verde y rojo. Luego convertimos a enteros de 32 bit, y con la instrucciones packusdw,

y packuswb empaquetamos de forma que queden en un xmm los bytes en orden azul, verde, rojo y transparencia. Este ultimo se consideran los bytes de la primera imagen almacenados en un registro xmm como se muestra la figura 8. Finalmente con la instrucción pshufb ordenamos los colores para que queden en el mismo orden en que ingresaron, y escribimos en memoria el resultado.

2.2.2. Implementación en assembler 2

Es análoga a la implementación anterior, pero en este caso se hacen la suma y multiplicación en números enteros. Se tiene en cuenta que la multiplicación de dos enteros, da como resultado un entero que puede ocupar el doble de tamaño. Para conseguir implementar el algoritmo con instrucciones enteras y obtener el mismo resultado (aunque se pierdan decimales), el método es multiplicar a todo por 256, hacer las multiplicaciones en enteros y finalmente dividir por 256.

Antes de empezar el ciclo, multiplicamos en punto flotante 256 y value, y al resultado lo convertimos a enteros. En este proceso se pierden decimales. Como value es un numero entre cero y uno, al multiplicar por 256 y pasarlo a enteros, tenemos un valor entre 0 y 256, con lo que ocupa menos de un byte de tamaño. Utilizando la instrucción pshufb y una mascara, almacenamos en un registro xmm 8 replicas de este valor. Luego hacemos la resta en enteros entre 256 y el valor obtenido en la multiplicación. Nuevamente tenemos un valor entero entre 0 y 256 que entra en un byte, almacenamos 8 replicas del mismo en un registro xmm tal como se ve en la figura 10. Estos registros serán utilizados para multiplicar los colores.

| 256-256*value |
|---------------|---------------|---------------|---------------|---------------|---------------|---------------|---------------|
| | | | | | | | |
| 256*value |

Figura 10: Contenido de los registros utilizados para multiplicar en enteros

El ciclo comienza igual que la implementación anterior, trayendo a un registro xmm 4 pixeles de la primer imagen desde memoria, ordenándolos con pshufb con una mascara para que queden como se indica en la figura 6. Utilizando punpcklbw y punpckhbw y un registro lleno de ceros obtenemos dos registros xmm, como pueden verse en a figura 7. Utilizando punpcklwd y psrldq, obtenemos finalmente tres registros xmm con el contenido tal como se indica en la figura 11.

0 0 0 A 0	0 0 A	0 0 0	A 0 0	0 A
0 0 0 0 0	0 0 0	0 B 0	B 0 B	0 B
0 R 0 R 0	R 0 R	0 G 0	G 0 G	0 G

Figura 11: Contenido de los registros luego de hacer operaciones de desempaquetado

Utilizamos las instrucciones pmullw y pmulhuw para obtener las partes altas y bajas de la multiplicación de los colores(sin contar la transparencia) con el valor 256*value(convertido a entero) que se encuentra almacenado en un registro como se indica en la figura 10. Finalmente utilizamos la instrucción punpcklwd y punpckhwd para obtener el resultado final de la multiplicación. De esta manera realizamos multiplicaciones de enteros de 16 bit, con lo que obtenemos enteros de 32 bit. El registro que contiene los bytes de transparencia queda inalterado.

Se repite el procedimiento para la segunda imagen, pero sin guardar los bytes de transparencia. Dividimos los enteros por 256 utilizando un corrimiento a derecha de 8 bit con la instrucción "psrld xmm, 8". Y luego sumamos en enteros con las instrucciones paddd. Se decide dividir primero y luego sumar para evitar una posible saturación. Con las instrucciones packusdw y packuswb empaquetamos el resultado, de forma que queden en un xmm los bytes en orden azul, verde, rojo y transparencia. Finalmente con la instrucción pshufb ordenamos los colores para que queden en el mismo orden en que ingresaron, y escribimos en memoria el resultado.

2.3. HSL

El espacio RGB que usamos hasta ahora está dado por un cubo donde cada componente corresponde a la intensidad de los colores primarios de la luz(rojo, verde y azul), para este filtro nos trasladamos al espacio HSL, este está dado por tres componentes: HUE(color), Saturation(Saturación) y Lightness(Luminosidad). Este espacio se representa gráficamente como un bicono donde cada punto esta determinado con: altura de la circunferencia a la que pertenece, radio de dicha circunferencia y ángulo dentro de la circunferencia, donde el color corresponde al ángulo, la saturación al radio y la luminosidad a la altura. El filtro consta de 3 etapas: (1)Transformación del espacio RGB a HSL del pixel, (2)suma de componentes y (3)transformación del espacio HSL a RGB cuyas formulas son las siguientes:

```
1. H:
   0 \text{ si } cmax = cmin
   60 * ((g-b)/d + 6) si cmax = r
   60 * ((b-r)/d + 2) si cmax = g
   60 * ((r-q)/d + 4) si cmax = b
   por ultimo si h>=360 entonces h=h-360
   L: (cmax + cmin) / 510
   S:
   0 \text{ si } cmax == cmin
   d/(1 - fabs(2 * l - 1))/255,0001f caso contrario
   para este caso se debe dividir contra 255.0001f para que s supere 1, evitando la propagación de
   errores.
   Donde cmax = max(b, g, r), min = min(b, g, r) y d = cmax - cmin
2. H:
   h + hh + 360 \text{ si } h + hh >= 360
   h + hh - 360 \text{ si } h + hh < 0
   h + hh caso contrario
   S:
   0 \text{ si } s + ss < 0
   1 \text{ si } s + ss >= 1
   s + ss caso contrario
```

donde hh, ll y ss son valores pasados por parámetro

L:

0 si l + ll < 01 si l + ll >= 1l + ll caso contrario

3. RGB:

r=c g=x b=0 si
$$0 <= h$$
 y $h < 60$
r=x g=c b=0 si $60 <= h$ y $h < 120$
r=0 g=c b=x si $120 <= h$ y $h < 180$
r=0 g=x b=c si $180 <= h$ y $h < 240$
r=x g=0 b=c si $240 <= h$ y $h < 300$
r=c g=0 b=x si $300 <= h$ y $h < 360$
Escala:

```
b = (b+n) * 255
g = (g+n) * 255
r = (r+n) * 255
```

donde:

$$\begin{split} c &= (1 - fabs(2*l - 1))*s; \\ x &= c*(1 - fabs(fmod(h/60, 2) - 1)) \\ m &= l - c/2 \end{split}$$

2.3.1. Implementación en assembler 1

OBS: Para esta implementación usamos dos funciones provistas por la cátedra (rgbTOhsl — hslTOrgb) y nos concentramos en (2), donde el algoritmo general va a recorrer la imagen como si fuera un vector, tomando pixel por pixel, transformándolo a HSL, luego procesándolo y finalmente transformándolo a RGB para devolverlo a memoria(para mas información sobre otras posibles implementaciones ver sección 4).

Recibimos como parámetros una imagen representada en memoria de la misma manera que en los anteriores filtros, ancho, alto y tres valores hh, ss y ll, los cuales modificaran los 3 elementos de la representación HSL del pixel. Primero acomodamos los datos de entrada de manera que nos queden dentro de un registro xmm, dado que cada dato ocupa 16bits los acomodamos de manera tal que los 3 elementos queden empaquetados.

LL SS HH 0

Figura 12: Organización de valores de entrada en registro XMM

A continuación movemos a un registro xmm el valor que usaremos como limite superior de la suma para h por un lado y s y l por otro ya que las modificaciones serán diferentes para los dos casos, como limite inferior simplemente colocaremos 0 en un registro usando pxor.

Dado que la imagen está representada linealmente en memoria vamos a recorrerla como un vector dentro de un ciclo principal que se moverá de a un pixel. Una vez dentro del ciclo procedemos a llamar a rgbTOhsl y movemos el pixel resultante a un registro xmm.



Figura 13: Contenido del registro XMM

Ahora sumamos los valores hsl con los que teníamos como parámetro con addps(a) para luego revisar los limites.



Figura 14: Contenido del registro XMM

Para realizar las comparaciones correspondientes primero generamos los vectores que sumados o restados nos den los resultados que queremos en cada caso, para esto tomamos por un lado un registro con el valor 360(b) en la posición de h y procedemos al primer caso de h, para esto aplicamos empleps para crear una mascara(c) en donde si h es mayor a 360 nos quedaran 1s en los valores donde se debería ubicar h o 0s en caso contrario, luego aplicamos pand usando (b) y (c) para finalmente restarlo a (a), dando como resultado (b) h + (b) h + (b) dependiendo del caso, a continuación veremos como se aplica esta idea a (c) y (c) para finalmente restarlo a (c) como se aplica esta idea (c) no (c) para finalmente (c) pa

0	0	360	0					
L + LL	S + SS	H + HH	0					
cmpelps								
0	0	1	0					
0	0	360	0					
	pa	ind						
0	0	360	0					
L + LL	S + SS	H + HH	0					
subps								
L + LL	S + SS	H + HH - 360	0					

Figura 15: ejemplo de estados usando cmp y and para el caso h mayor a 360

Para s y l, como su resultado debe ser 1 en caso de pasar el limite, simplemente colocamos s+ss-1 y l+ll-1 empaquetados en un registro aparte pero en las mismas posiciones que s+ss y l+ll respectivamente, luego aplicamos la misma idea que en la figura 10 pero comparando contra 1 en lugar de 360 y finalmente sumando s+ss-1 o l l+ll-1 según corresponda para lograr que quede 1 ó s+ss/l+ll en los valores finales. Los casos de los limites inferiores que se realizan inmediatamente después en el código son análogos pero comparando contra 0s, dando una sucesión de estados con la cual al llegar al final, (1) tendrá los valores l+ll ó 1 ó 0, s+ss ó 1 ó 0, h+hh ó h+hh+360 ó h+hh-360 y 0 respectivamente en sus posiciones empaquetadas.

2.3.2. Implementación en assembler 2

Para esta implementación reutilizamos el código de la primera y nos concentramos en implementar (1) y (3)

Transformación del espacio RGB a HSL

Como parámetros tenemos el puntero al pixel de la matriz que queremos convertir y un vector de floats donde guardar la versión hsl del pixel. Primero levantamos el pixel a un registro de propósito general y lo movemos de a bytes a otros registros para separar los elementos RGBA del pixel, como cada uno ocupa 1B simplemente movemos entre registros de 1B y luego shifteamos al que contiene todo el pixel 1B a la derecha hasta que queden todos separados.

A continuación pasamos a calcular el máximo entre RGB, para esto acumulamos uno de los tres valores y comparamos contra los otros acarreando siempre al mayor, análogamente para calcular el mínimo. Luego calculamos D, para esto simplemente colocamos el máximo en otro registro y le restamos el mínimo.

Después calculamos H, para esto separamos los casos posibles en donde simplemente seteamos los registros que luego serán operados, esto se logra comparando el máximo contra los posibles valores, saltando, seteando los registros según los valores que les correspondan, convirtiéndolos en valores de punto flotante con cvtdq2ps y finalmente utilizando subps, divps, addps y mulps para llegar a la formula que les corresponda.

$$60 * ((d-b)/d + 4)$$

Figura 16: (contenido del registro xmm al final del caso 3, para mas información sobre los casos ver el código fuente)

por ultimo revisamos que no haya caído fuera de rango, para esto aplicamos la misma técnica que en la primera implementación usando una comparación y luego aplicando pand y subps para llegar a h ó h-360.

Ahora calculamos L, para esto tomamos el máximo y le sumamos el mínimo, lo pasamos a un registros xmm, lo convertimos y aplicamos una división contra una posición en memoria que contiene 510.

Por ultimo queda calcular S, en caso de que sea igual al mínimo simplemente lo seteamos en 0, caso contrario pasamos a efectuar las cuentas. Movemos d a un registro xmm y lo convertimos a punto flotante, luego usamos addps, mulps y subps para llegar a 2*l - 1 donde aplicamos pand contra una mascara que contiene todos 1 excepto en el bit mas significativo, de esta manera seteamos en 0 el bit de signo de la representación del float que contiene 2*l - 1, convirtiéndolo en abs(2*l - 1). Finalmente dividimos a d por abs(2*l - 1) y luego por 255.0001 desde una dirección en memoria que lo contiene.



Figura 17: Representación del punto flotante en memoria

Terminado lo anterior procedemos a empaquetar los datos con punpckldq de manera que dentro del registro quede LHSA para que cuando lo volquemos a memoria sea de la forma ASHL.

Transformación del espacio HSL a RGB

Como parámetros tenemos un vector de floats donde se encuentra la versión hsl del pixel y el puntero al pixel de la matriz donde queremos colocar su versión RGB. Primero levantamos el pixel a un registro xmm y separamos sus componentes entre otros registros xmm usando punpckldq, punpckhdq, psrldq y pslldq.

Luego calculamos C, para esto levantamos de memoria un 1 a un registro xmm y pasamos a realizar las cuentas usando addss, mulss y subss hasta llegar a 2*l-1 donde aplicamos pand contra una mascara de la misma que en la transformación anterior para lograr abs(2*l - 1), luego le restamos a 1 el resultado y lo multiplicamos por S.

A continuación calculamos X, para esto pasamos el valor 60 a un registro xmm, lo convertimos a float y dividimos H por 60, luego para calcular fmod(h/60, 2), simplemente restamos 60 hasta que el numero sea menor a 2 ya que como el primer operando es h/60, ese numero estará entre 0 y 60, como siguiente operación resto y aplico la misma idea de mascara para lograr abs(fmod(h/60, 2) - 1) y finalmente resto 1 y multiplico por C.

En este punto nos queda calcular M y luego ordenar lo que ya calculamos, empecemos con lo primero. Simplemente copio el valor C a otro registro, lo dividimos por dos y se lo restamos a l.

Ahora vamos a calcular RGB, en esta parte nos dedicamos a ver a que valor(r, g o b) corresponden X y C respectivamente, para esto preguntamos linealmente, aumentando de a 60 en que caso cae H, sumándole 60 y comparando contra H con comiss para luego efectuar un jb de ser necesario. Dentro de cada caso se tiene un registro xmm que contiene a C y un registro de propósito general que contiene a X y, dependiendo del caso, se shiftea C hasta el lugar que corresponda a la componente a la que debe ir y luego se aplica pinsrd para insertar X en la posición que le corresponda.

Finalmente nos queda calcular la escala, para esto primero colocamos M en un registro xmm, lo shifteamos y sumamos con pslldq y addps contra M hasta que queden tres valores iguales empaquetados en la posiciones donde deben ir r, g y b, a continuación se suma este registro con addps al que contenía a C y X y se lo multiplica por 255 contra un registro que previamente había levantado ese valor de memoria,

para lograr (X + M) * 255 en cada una de las componentes. Luego se inserta A en la ultima posición y se convierte a entero truncando el valor, se tomo esta decisión ya que la conversión normal redondeaba al entero más cercano.

Para ordenar los datos(ya que deben tener 1B cada uno y a esta altura tienen 4B) aplicamos pshufb sobre el registro que contiene RGBA para pasar dichos valores a 1B(tomando solo el primer byte de estos) en sus posiciones finales y luego moverlo a memoria(figura 14).

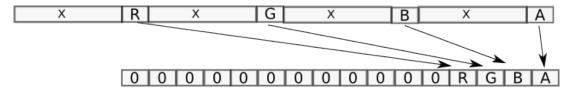


Figura 18: Uso de pshufB

3. Experimentación

Se llevaron a cabo experimentos para comparar el tiempo de computo de las distintas versiones de los filtros, en assembler y en C, con distintas optimizaciones. Se estudio el tiempo de computo para distintos parámetros de los filtros, y utilizando distintos conjuntos de imágenes: Normal(incluyen todos los colores), Black(imágenes negras), White(imágenes blancas).

3.1. Blur

En las siguientes figuras encontramos los resultados obtenidos para el filtro blur:

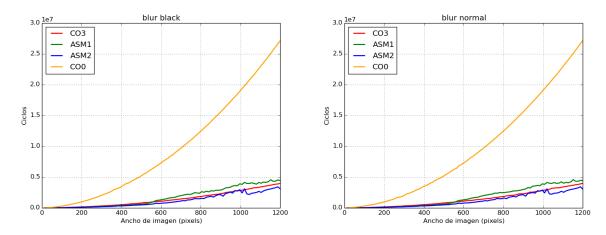


Figura 19: Rendimiento del filtro blur para imágenesFigura 20: Rendimiento del filtro blur para imágenes negras normales.

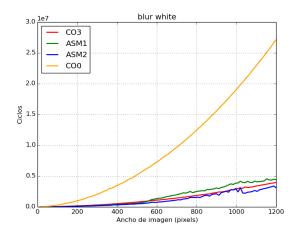


Figura 21: Rendimiento del filtro blur para imágenes blancas.

Las dos implementaciones en assembler, utilizan una memoria temporal del tamaño de la imagen para ir almacenando los resultados parciales. Como trabajamos con imágenes pequeñas, esto no resulta costoso, pero podría ser evitado con un algoritmo mas complejo.

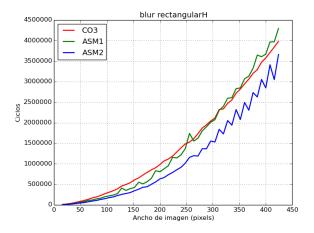
La segunda implementación en assembler en comparación con la primera resulta tener un rendimiento un poco mejor. Esto se debe a que esta ultima realiza tres lecturas de memoria y una escritura para escribir en la memoria temporal un pixel, en cambio la segunda utiliza cuatro lecturas y cuatro escrituras de memoria para escribir en la memoria temporal cuatro pixeles. Esta ultima podría ser mejorada para que con una escritura escribir los cuatro pixeles en memoria, en lugar de hacerlo con accesos separados.

La implementación en C sin optimización resulta ser mucho mas costosa que las otras, lo cual se puede deber a que por cada color realiza una suma y un acceso a memoria, lo que implica una cantidad de accesos a memoria muy grande. La implementación en C optimizada resulta tener un rendimiento mejor que una versión de assembler, pero peor que el otro.

Al no tener saltos condicionales, obtenemos el mismo rendimiento para los distintos tipos de imágenes como se puede ver en los gráficos 19, 20 y 21.

3.1.1. Metodo de iteración

Teniendo en cuenta la decisión de hacer una iteración de arriba a abajo y de izquierda a derecha de la imagen (para cargar solo una linea por pixel a procesar) se realizaron experimentos para ver si esta decisión realmente mejora el tiempo de procesamiento. Para esto se ejecutó el blur sobre dos image sets, uno ('rectangularH') de imágenes con w=8*h y el otro ('rectangularW') con imagines con h=8*w, quiere decir, un set con imágenes altas y delgadas, y otro con bajas y anchas. La hipótesis es que debería ser mas rápido el procesamiento de 'rectangularH' que el de 'rectangularW' ya que cuando la iteración llega a y=h-2 se aumenta x y hay que cargar las tres primeras filas (tres lecturas de memoria) de la siguiente columna para poder seguir con el procesamiento. Entonces rectangularH tendría que hacer menos veces ese proceso, y rectangularW mas. El resultado de esta experimentación es el siguiente:



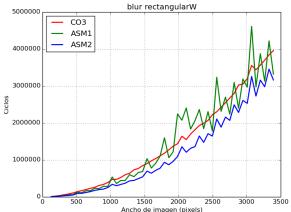


Figura 22: Rendimiento para rectangularH

Figura 23: Rendimiento para rectangularW

Como se ve no hay una diferencia importante en el tiempo de procesamiento final, de hecho procesar rectangularW termina tardando menos que Rendimiento para rectangularH. Como se ve también, rectangularW tiene mucho ruido, y es muy interesante ver como ASM1 tiene el mismo ruido que ASM2 pero amplificado, esto quiere decir que no es realmente ruido, sino que, analizando los datos de salida del experimento, estos picos se dan cuando las dimensiones de la imagen son múltiplo de 32, por lo tanto llegamos a la conclusión que por algún motivo baja el hit rate del cache, pero no se nos pudieron ocurrir otras pruebas para comprobar esto.

Otra conclusión a la que llegamos es que la decisión sobre la forma de iterar la imagen fue equivocada, ya que si, se carga una sola linea de 4 pixeles por cada pixel a procesar, pero si se hiciera la iteración de izquierda a derecha y de arriba a abajo, se cargarían tres lineas de 4 pixeles por pixel a procesar, lo que es un mayor acceso a memoria, pero como siempre (excepto al llegar al final de la linea) se cargan tres lineas que empiezan en la columna siguiente a las de la iteración anterior, es seguro que van a estar en cache (si el cache copia bloques de 32 bits, va a haber 1 miss y 28 hits porque se carga de a 4 pixeles). Esto hace que sea muy probablemente mas eficiente que la iteración implementada.

3.2. Merge

En las siguientes figuras encontramos los resultados obtenidos para el filtro merge:

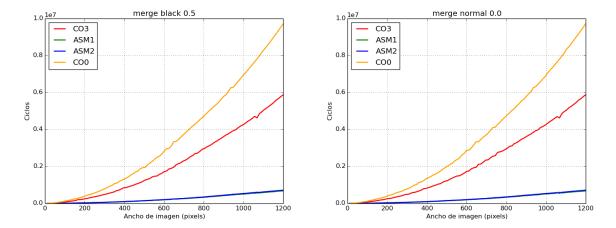


Figura 24: Rendimiento para un value de 0.5, imáge-Figura 25: Rendimiento para un value de 0.0, imágenes negras.

nes normales.

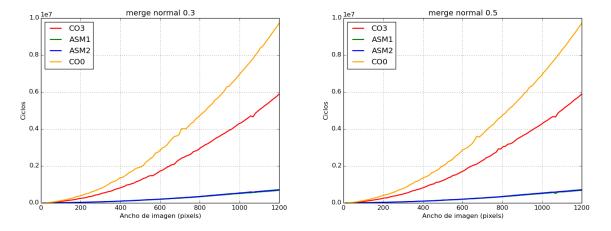


Figura 26: Rendimiento para un value de 0.3, imáge-Figura 27: Rendimiento para un value de 0.5, imágenes normales.

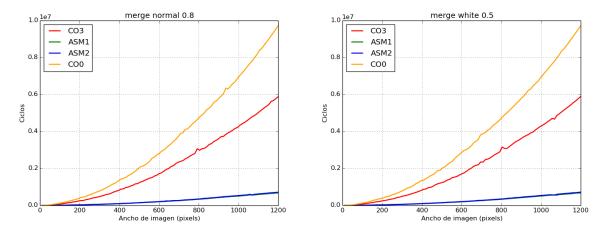


Figura 28: Rendimiento para un value de 0.8, imáge-Figura 29: Rendimiento para un value de 0.5, imágenes normales.

nes blancas.

Para todas las implementaciones el tiempo de computo con respecto a la cantidad de pixeles crece según la curva indicada en el gráfico, lo cual indica un ritmo de crecimiento bien marcado, que podría ser definido matemáticamente.

En base a estos resultados, podemos decir que la implementación en C tiene un rendimiento menor, aun utilizando un compilador que optimiza. Esto se debe a que la imágenes se encuentran almacenadas en memoria en forma de matrices de pixeles y, en la implementación en assembler, se traen desde memoria cuatro pixeles a un registro xmm, a diferencia de la implementación en C, en la cual se hace un acceso a memoria por color. Con lo que la cantidad de accesos a memoria es mucho menor en la implementación en assembler, lo que implica un tiempo de computo mucho menor. Además en la implementación en assembler, utilizando las instrucciones simd se hacen multiplicaciones y sumas de a cuatro colores, a diferencia de la C, en la estas operaciones se hacen color por color.

Tanto las implementaciones en C como en assembler de este filtro presentan el mismo rendimiento para los distintos tipos de imágenes, y solo dependen de la cantidad de pixeles a procesar. Esto se debe a que ambas implementaciones no presentan saltos condicionales. Tampoco hay diferencia apreciable para los distintos valores de value.

Para las implementaciones en assembler, no hay grandes diferencias entre el tiempo de computo al operar con enteros o con floats. A pesar de que en teoría trabajar con los primeros se tiene un costo computacional menor, al haber involucradas multiplicaciones con instrucciones SIMD, también hubo que utilizar instrucciones de empaquetado-desempaquetado para efectuar multiplicaciones con enteros, lo conlleva lleva un costo que debe considerarse. En la figura 30 se puede apreciar como la versión en enteros tiene un costo computacional ligeramente mayor.




Figura 30: Merge: ASM1 vs ASM2

A pesar de que los algoritmos utilizados no son probabilísticos, es decir que para la misma entrada se obtiene siempre la misma salida, hay diferencias entre la imagen generada por el ejecutable elaborado por nosotros, y la obtenida mediante el provisto por la cátedra. Esto se debe a que los algoritmos utilizados por los ejecutables, a pesar de cumplir la misma función, son distintos, y van acumulando fuentes de error. Para la implementación en floats, las operaciones aritméticas generan errores numéricos de redondeo, lo cual produce que a pesar de que semanticámente se llegue a la misma salida a partir de una dada entrada, halla diferencias debido a la propagación de errores numéricos.


En el caso de la implementación en enteros, la fuente de error ocurre cuando se convierte a entero value*256, en lo cual se pueden perder decimales. Luego las operaciones son efectuadas en enteros, con lo que se descartan errores numéricos. Esto significa que si en la implementación elaborada por la cátedra se utilizo la misma técnica para trabajar con enteros, debería haber diferencia cero entre las distintas salidas para una misma entrada. En los experimentos esto no se observa, por lo que es de esperar que se halla utilizado otra técnica similar.

3.3. HSL

Para experimentar con este filtro primero analizamos un poco el código. Este se divide en 3 etapas: (1)RGB a HSL, (2)suma y (3)HSL a RGB.

3.3.1. Implementación

Analizando (2) podemos observar que realiza siempre la misma cantidad de operaciones dado que no contiene ningún salto condicional, por lo que podemos asumir que es constante(ver Figuras 22 y 23).






Figura 31: Rendimiento para un H de 0, imágenesFigura 32: Rendimiento para un 0 de 300, imágenes normales.

La implementación de (2) en HSL1 si bien utiliza operaciones empaquetadas como addps o cmpleps para operar h o l y s al mismo tiempo, tiene un rendimiento mucho menor que la implementación en C con O0 y O3(ver figure 22 y 23) ya que es la implementación standard del filtro, en la sección 4 proponemos una variación que podría aumentar este rendimiento considerablemente.

Ahora analicemos HSL2, mas en particular (1). Con las imágenes normales, se esperó que los tiempos de corrida fueran mejores en términos de rendimiento que las implementaciones de C con optimización pero en lugar de eso se puede observar que solo corre más rápido en los casos donde hh es 0 o 360(ver figuras 24, 25 y 26), suponemos que se debe a que este cacheando el acceso a memoria debido a que el valor no cambia en la suma ya que: h + hh >= 360 => h = h + hh - 360, reemplazando hh por 360 nos queda: h + 360 - 360 = h entonces no varia y dado que no estamos modificando s y l, el valor que queramos asignar al momento de aplicar "movdqu [dir], xmm", donde xmm contiene los valores l, h y s finales, será el mismo que al principio, por lo que no habría necesidad de efectuarlo y el valor que fue cacheado al momento de levantar memoria por primera vez continuara cacheado, evitando acceder nuevamente a memoria.




Figura 33: Rendimiento para un H de 0, imágenesFigura 34: Rendimiento para un H de 240, imágenes normales.

El caso donde el máximo y el mínimo de r, g y b son iguales realiza menos operaciones dado que por las formulas que conlleva calcular H y S, en este caso simplemente colocara un 0 en H y continuara a calcular L y por ultimo solo colocara un 0 en S siendo mucho mas corto el proceso.(ver figuras 27 y 26)





Figura 35: Rendimiento para un H de 360, imágenesFigura 36: Rendimiento para un 0 de 360, imágenes negras normales.

3.3.2. Variación 1

Probamos cambiar dentro de la función çalcRGB"la manera de ordenar los datos, en lugar de aplicar pslldq y luego pins usamos pshufd, dando como resultado un rendimiento casi parecido donde la variación fue un poco mas lenta(figuras 28 y 29)







Figura 37: Rendimiento para un H de 360, imágenesFigura 38: Rendimiento para un H de 360, imágenes normales.

3.3.3. Variación 2

Como segunda variación decidimos cambiar la manera en que esta implementada la función "fmod" dentro de çalcX. en (3) la cual hasta el momento resta 60 hasta que el valor sea menor a 0. La propuesta fue usar la siguiente formula: mod(n,m) = n - (parteentera(n/m)*m) usando cvttss2si para truncar la parte decimal del dato y luego cvtsi2ss para devolverlo a float. Esta variación bajo el rendimiento dado que la conversión de float a entero y viceversa es muy costosa. (ver figuras 30 y 31)






Figura 39: Rendimiento para un H de 360, imágenesFigura 40: Rendimiento para un H de 360, imágenes normales.

normales, variación 2.

3.3.4. Experimentos Futuros

- 1. Si observamos (3) podemos llegar a tener mas operaciones mientras h sea mayor ya que la función çalcRGB"pregunta linealmente si h pertenece a un intervalo determinado, incrementándolo de a 60 y volviendo a preguntar, entonces si 0 <= h < 60 debería entrar mas rápido que si 300 <= h < 360, para esto se podría usar una imagen que tengo uno de los colores(ej: solo rojo) y comparar los tiempos contra una que tenga solo blanco.
- 2. Implementar parte entera en la variación 2, eliminando la parte decimal de la mantisa de la representación en punto flotante del numero a mano podría aumentar bastante el rendimiento.

4. Conclusiones y trabajo futuro

Pudimos corroborar el uso del assembler para conseguir algoritmos mas eficientes temporalmente, aunque al ser un lenguaje de mas bajo nivel sea mas difícil de escribir. En este sentido se utilizaron las instrucciones SIMD de assembler, permitiéndonos mejorar la eficiencia, al efectuar varias operaciones juntas. Sin embargo muchas veces es necesario preparar los registros para efectuar estas instrucciones y esto puede no ser sencillo, o tener un costo temporal elevado.

Además la ganancia en rendimiento de efectuar operaciones SIMD no es tan importante como reducir la cantidad de accesos a memoria. Se pudo apreciar que al reducir la cantidad de estos últimos, se logra una mejora en el rendimiento significativa.

Como trabajo pendiente queda la implementación de una variante de la primera implementación de HSL en donde para sumar las componentes hh, ss y ll en lugar de agarrar un solo pixel, ordenar los datos de manera que podamos tener 4 h's, l's y s's a la vez y procesar 4 pixeles al mismo tiempo.